

Modelagem Nebulosa para Controle de Ultrapassagem em Veículos Terrestres Autônomos

Igor Muniz Nascimento
<igor.muniz@estudante.ufjf.br>

19 de Setembro de 2024

Resumo

Este artigo apresenta o desenvolvimento de um Sistema de Inferência Nebulosa (SIN) para o controle de ultrapassagem em veículos terrestres autônomos (VTA). O modelo utiliza variáveis como distância, velocidade relativa, permissão de ultrapassagem, condições da pista e visibilidade para determinar se a ultrapassagem pode ser iniciada com segurança. O processo de fuzzificação, ou seja, a transformação de variáveis numéricas em variáveis nebulosas, foi aplicado para lidar com a incerteza das condições reais de tráfego. O modelo proposto é baseado no método de Mamdani, e foi implementado para fuzzificação das variáveis de entrada, criação de regras de inferência e defuzzificação para a saída. Os resultados demonstram a eficácia do sistema na tomada de decisões seguras de ultrapassagem em diferentes cenários.

Palavras-chaves ultrapassagem; veículo autônomo; inferência nebulosa; controle de tráfego; segurança.

Abstract

This paper presents the development of a Fuzzy Inference System (FIS) for overtaking control in autonomous ground vehicles (ATVs). The model uses variables such as distance, relative speed, overtaking permission, road conditions, and visibility to determine whether overtaking can be initiated safely. The fuzzification process, which transforms numerical variables into fuzzy variables, was applied to manage the uncertainty of real traffic conditions. The proposed model is based on the Mamdani method, and was implemented to fuzzify the input variables, create inference

rules, and defuzzify the output. The results demonstrate the system's effectiveness in making safe overtaking decisions in various scenarios.

Keywords overtaking; autonomous vehicle; fuzzy inference; traffic control; safety.

1 Introdução

Nos últimos anos, os Veículos Terrestres Autônomos (VTA) têm se destacado como uma das principais inovações tecnológicas com potencial para transformar significativamente a segurança no trânsito. Esses veículos prometem reduzir acidentes e otimizar o fluxo de tráfego, além de melhorar a eficiência do transporte rodoviário. Contudo, uma das tarefas mais desafiadoras para os VTAs é a tomada de decisão relacionada à ultrapassagem, especialmente em condições de tráfego dinâmicas e variáveis, como visibilidade reduzida, mudanças no comportamento dos veículos à frente e diferentes condições da estrada.

Iniciar uma ultrapassagem requer a avaliação de diversos fatores críticos, como a distância segura em relação ao veículo à frente, a diferença de velocidade entre os veículos, a presença de obstáculos na pista oposta e as condições de visibilidade. Estes fatores, muitas vezes incertos e parcialmente observáveis, tornam o processo de decisão complexo [2].

Este trabalho propõe o uso de um modelo de inferência nebulosa (fuzzy) para auxiliar os VTAs na decisão de ultrapassagem. A lógica nebulosa é uma ferramenta adequada para lidar com incertezas, pois permite modelar variáveis subjetivas como "distância segura" ou "boa visibilidade". O modelo usa variáveis como distância, velocidade relativa, permissão de ultrapassagem, condições da pista e visibilidade para determinar se a ultrapassagem pode ser realizada de forma segura [3].

O modelo de inferência nebulosa é baseado na técnica de Mamdani, que permite a interpretação de regras linguísticas e a tomada de decisões de controle. O sistema realiza a fuzzificação das variáveis de entrada, aplica regras de inferência baseadas em conhecimento especializado e executa o processo de defuzzificação para gerar uma saída que indica se a ultrapassagem deve ser iniciada [4].

1.1 Problema

A questão central abordada neste trabalho é: “Em quais condições um Veículo Terrestre Autônomo (VTA) deve iniciar uma manobra de ultrapassagem em um ambiente com tráfego e condições rodoviárias variáveis?”. A complexidade da resposta a essa pergunta decorre da necessidade de avaliar simultaneamente diversos fatores críticos, como a distância entre o VTA e o veículo à frente, a diferença de velocidade relativa entre eles, as permissões legais de ultrapassagem vigentes no local, além das condições da pista e da visibilidade [2]. Cada um desses elementos exerce influência direta na segurança da manobra, exigindo uma análise integrada e precisa para garantir que a ultrapassagem seja

realizada de forma segura e eficiente. Dessa forma, o presente estudo busca desenvolver um modelo de inferência capaz de incorporar essas variáveis, lidando com a incerteza inerente ao ambiente de tráfego real, e assim fornecer uma base de decisão robusta para os VTAs.

2 Contextualização

Atualmente, os sistemas de controle de veículos autônomos são amplamente baseados em regras rígidas fundamentadas em lógica booleana ou algoritmos determinísticos. Embora essas abordagens possam ser eficazes em cenários padronizados e controlados, elas apresentam limitações significativas quando aplicadas às condições dinâmicas e imprevisíveis das estradas reais. Situações como variações topográficas (subidas e descidas), presença de curvas, mudanças climáticas adversas e eventos de tráfego inesperados são exemplos de fatores que introduzem uma alta variabilidade e incerteza, dificultando a aplicação de soluções determinísticas tradicionais [2]. Este trabalho propõe um avanço significativo ao implementar um modelo de inferência nebulosa, capaz de lidar com a incerteza e a complexidade desses cenários [5]. A lógica nebulosa proporciona maior flexibilidade e adaptabilidade, permitindo que o sistema tome decisões de ultrapassagem de maneira mais eficaz e segura, considerando a variabilidade dos fatores ambientais e operacionais [3]. Assim, o modelo proposto representa uma solução mais robusta e eficiente para a tomada de decisão em veículos terrestres autônomos.

3 Objetivo

O objetivo deste estudo é desenvolver um sistema de inferência nebulosa (SIN) capaz de determinar, de maneira eficaz, se um veículo terrestre autônomo (VTA) pode iniciar uma ultrapassagem de forma segura, considerando um conjunto de variáveis linguísticas [4]. Ao abordar essa lacuna existente nos sistemas atuais de controle de VTA, espera-se que o SIN contribua significativamente para a melhoria da segurança, ao proporcionar decisões mais precisas e adequadas, levando em conta fatores como as condições da estrada, o comportamento do tráfego e outras variáveis dinâmicas [3]. Esse avanço permitirá que os veículos autônomos atuem de forma mais adaptativa e eficiente em cenários complexos, reduzindo riscos e aumentando a confiabilidade do sistema [5].

4 Metodologia

A metodologia deste estudo é baseada no desenvolvimento de um Sistema de Inferência Nebulosa (SIN) para auxiliar na decisão de ultrapassagem de veículos terrestres autônomos (VTA). O processo metodológico foi estruturado em três etapas fundamentais: a

definição das variáveis linguísticas de entrada, a construção das regras de inferência e a implementação de um modelo de defuzzificação para a tomada de decisão.

Inicialmente, foram estabelecidas as variáveis linguísticas essenciais para a modelagem da ultrapassagem, levando em consideração fatores como distância entre veículos, velocidade relativa, condições de visibilidade, estado da pista e permissão legal para a manobra. **Velocidade relativa** é definida como a diferença entre a velocidade do veículo autônomo e a velocidade do veículo à frente, conforme a seguinte equação:

$$v_{rel} = v_{ego} - v_{outro} \quad (1)$$

onde v_{rel} representa a velocidade relativa, v_{ego} é a velocidade do veículo autônomo (veículo ego) e v_{outro} é a velocidade do veículo à frente.

A **distância mínima de segurança** também é uma variável crucial no processo de decisão de ultrapassagem. De acordo com recomendações práticas, a distância mínima entre dois veículos que trafegam no mesmo sentido deve ser de 5 metros para cada 16 km/h. Utilizando essa regra, é possível estimar a velocidade do veículo à frente, dada a distância segura e a velocidade do veículo autônomo.

Por exemplo, considerando que o veículo autônomo trafega a 80 km/h (equivalente a aproximadamente 22,22 m/s) e a distância segura entre os dois veículos é de 20 metros, podemos calcular a velocidade do veículo à frente (v_{outro}) utilizando a regra de distância segura:

$$v_{outro} = \frac{d}{5 \text{ m}} \times 16 \text{ km/h} \quad (2)$$

Substituindo os valores:

$$v_{outro} = \frac{20 \text{ m}}{5 \text{ m}} \times 16 \text{ km/h} = 4 \times 16 \text{ km/h} = 64 \text{ km/h} \quad (3)$$

Portanto, o veículo à frente trafega a aproximadamente 64 km/h.

4.1 Cálculo da Velocidade Relativa

Agora, utilizando a velocidade do veículo autônomo e a velocidade estimada do veículo à frente, podemos calcular a **velocidade relativa** entre os dois veículos. Considerando que o veículo autônomo está a 80 km/h (equivalente a 22,22 m/s) e o veículo à frente está a 64 km/h (equivalente a 17,78 m/s), a velocidade relativa (v_{rel}) é dada por:

$$v_{rel} = v_{ego} - v_{outro} \quad (4)$$

Substituindo os valores:

$$v_{rel} = 22,22 \text{ m/s} - 17,78 \text{ m/s} = 4,44 \text{ m/s} \quad (5)$$

Portanto, a velocidade relativa entre os dois veículos é de aproximadamente 4,44 m/s (ou 16 km/h). Isso significa que o veículo autônomo está se aproximando do veículo à frente com uma diferença de velocidade de 16 km/h.

4.2 Cálculo da Distância Segura

Adicionalmente, podemos realizar o cálculo do tempo mínimo de segurança com base na conversão de velocidade de 16 km/h para metros por segundo. A conversão de 16 km/h para m/s é realizada da seguinte forma:

$$16 \text{ km/h} = \frac{16}{3,6} \text{ m/s} \approx 4,44 \text{ m/s} \quad (6)$$

Agora, podemos calcular o tempo necessário para manter uma distância segura de 5 metros entre os veículos:

$$\text{tempo} = \frac{5 \text{ m}}{4,44 \text{ m/s}} \approx 1,125 \text{ segundos} \quad (7)$$

Isso significa que, para uma velocidade de 16 km/h, o intervalo de tempo seguro entre os veículos é de aproximadamente 1,125 segundos.

Após a definição das variáveis de entrada, foram desenvolvidas as regras de inferência utilizando a metodologia de Mamdani, amplamente reconhecida pela sua eficácia na modelagem de sistemas complexos e sujeitos a incertezas. As regras de inferência determinam, de maneira gradual e flexível, se a ultrapassagem pode ser iniciada com segurança. Essas regras são fundamentadas em normas de segurança viária e práticas observacionais, assegurando que o sistema opere dentro dos padrões de segurança exigidos.

Por fim, foi implementado o modelo de defuzzificação, que converte as saídas nebulosas em decisões concretas. O método do centro de gravidade foi utilizado para calcular um valor final que indica a probabilidade de se iniciar a ultrapassagem. Essa abordagem permite ao sistema lidar com diferentes cenários de trânsito, minimizando o risco de decisões abruptas e promovendo uma operação adaptativa e eficiente.

4.3 Variáveis Linguísticas

Para o desenvolvimento do sistema de inferência nebulosa, foram definidas cinco variáveis de entrada que influenciam na decisão de iniciar ou não uma ultrapassagem: distância entre os veículos, velocidade relativa do veículo, permissão de ultrapassagem, condições da pista, e visibilidade. Além disso, foi definida uma variável de saída que representa a decisão de ultrapassagem.

Cada uma dessas variáveis foi representada por funções de pertinência para lidar com a incerteza das informações e fornecer uma base gradual de avaliação. As variáveis linguísticas foram definidas da seguinte maneira:

- **Distância:** Esta variável foi dividida em três termos linguísticos — "pequena", "média" e "grande". Distâncias menores que 20 metros são consideradas pequenas, enquanto distâncias acima de 40 metros são tratadas como grandes.




Figura 1 – Gráfico de pertinência para a variável "distância".

- **Velocidade Relativa:** A velocidade relativa foi classificada como "baixa", "média" e "alta", considerando o intervalo entre 0 e 56 m/s. Velocidades acima de 40 m/s são definidas como altas, o que pode indicar a necessidade de ultrapassagem.




Figura 2 – Gráfico de pertinência para a variável "velocidade".

- **Permissão de Ultrapassagem:** A variável permissão reflete a autorização para ultrapassar, com termos "não permitido" e "permitido". Utilizou-se uma função de pertinência com transição suave entre 0.4 e 0.6.

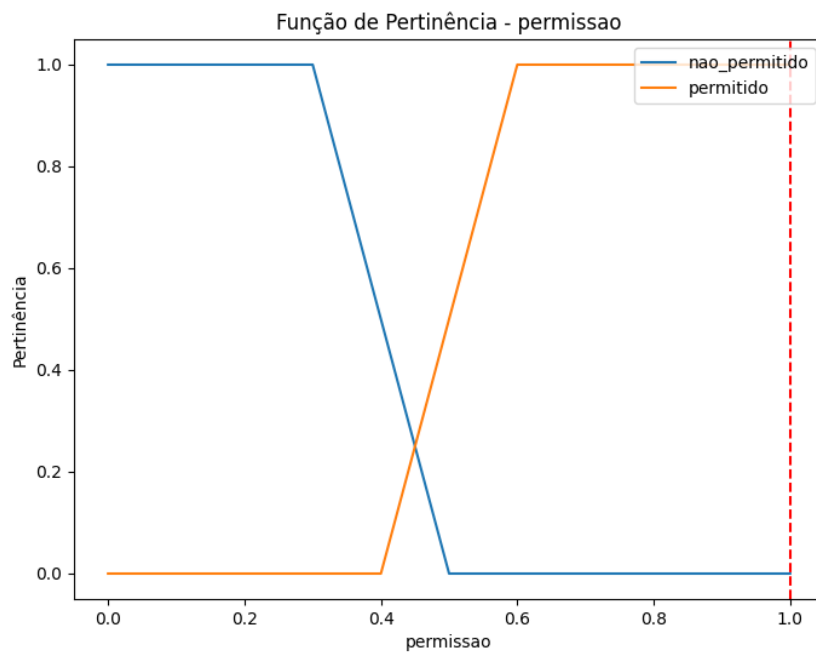


Figura 3 – Gráfico de pertinência para a variável "permissão".

- **Pista:** A condição da pista é descrita como "livre" ou "obstruída", também com transição suave. Pistas com valores acima de 0.6 são tratadas como livres.

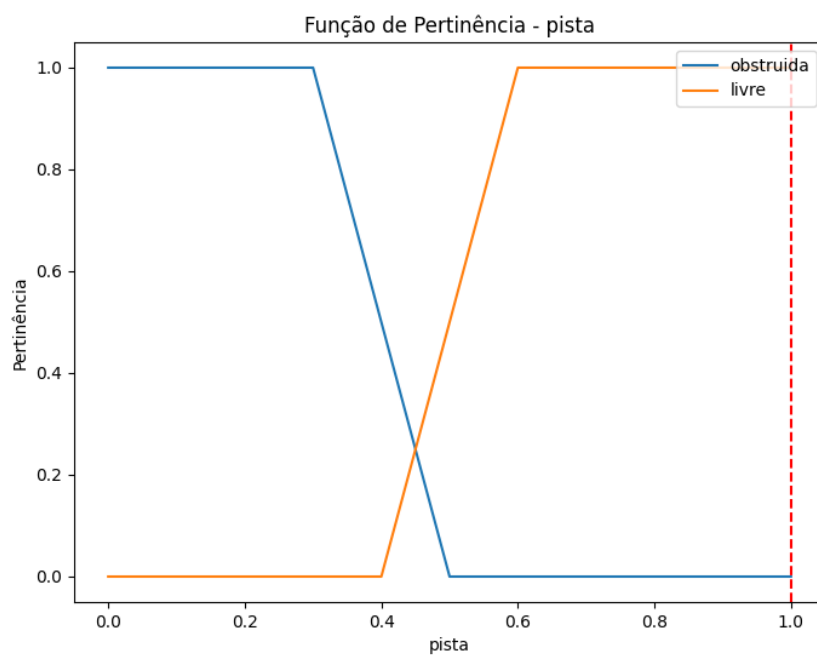


Figura 4 – Gráfico de pertinência para a variável "pista".

- **Visibilidade:** A visibilidade foi modelada com termos "ruim" e "boa". Condições de visibilidade acima de 0.6 são consideradas favoráveis para ultrapassagem.

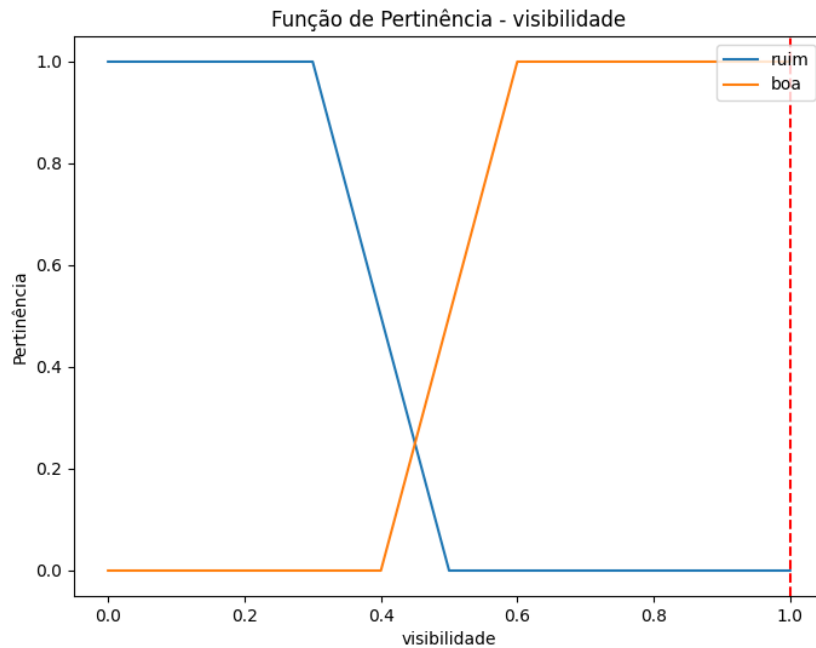


Figura 5 – Gráfico de pertinência para a variável "visibilidade".

A variável de saída, decisão de ultrapassagem, foi definida como sim (0.5 a 1) ou não (0 a 0.5), representando a recomendação do sistema quanto à segurança da manobra. Cada variável foi modelada com suas respectivas funções de pertinência utilizando o método de Mamdani.

4.4 Regras de Inferência

As regras de inferência foram formuladas para capturar as condições sob as quais uma ultrapassagem deve ser recomendada ou evitada. Foram definidas 15 regras principais, incluindo:

- **Regra 1:** Se a distância é pequena e a velocidade relativa é alta, com permissão e pista livre e boa visibilidade, então deve-se ultrapassar.
- **Regra 2:** Se a distância é pequena e a velocidade relativa é média, com permissão e pista livre e boa visibilidade, então deve-se ultrapassar.
- **Regra 3:** Se a distância é média e a velocidade relativa é alta, com permissão e pista livre e boa visibilidade, então deve-se ultrapassar.
- **Regra 4:** Se a distância é média e a velocidade relativa é média, com permissão e pista livre e boa visibilidade, então deve-se ultrapassar.
- **Regra 5:** Se a distância é grande ou a velocidade relativa é baixa ou a pista está obstruída, então não deve ultrapassar.

- **Regra 6:** Se a visibilidade é ruim, então não deve ultrapassar, independentemente das outras condições.
- **Regra 7:** Se a permissão é negada, então não deve ultrapassar.
- **Regra 8:** Se a pista está obstruída, então não deve ultrapassar.
- **Regra 9:** Se a distância é pequena e a velocidade relativa é baixa, com permissão e pista livre, então deve-se ultrapassar.
- **Regra 10:** Se a distância é grande e a velocidade relativa é alta, então não deve ultrapassar.
- **Regra 11:** Se a distância é média e a velocidade relativa é alta, com pista livre e boa visibilidade, então deve-se ultrapassar.
- **Regra 12:** Se a distância é grande e a velocidade relativa é média, e a pista está livre, então não deve ultrapassar.
- **Regra 13:** Se a velocidade relativa é muito alta, com permissão e boa visibilidade, então deve-se ultrapassar.
- **Regra 14:** Se a velocidade relativa é baixa e a visibilidade é ruim, então não deve ultrapassar.
- **Regra 15:** Se a pista está obstruída ou a permissão é negada, então não deve ultrapassar.

Essas regras foram desenvolvidas com base em heurísticas do tráfego, refletindo as condições mais comuns e seguras para ultrapassagem.

4.5 Fuzzificação e Defuzzificação

A etapa de fuzzificação foi aplicada a todas as variáveis de entrada do sistema, convertendo seus valores numéricos em graus de pertinência associados a termos linguísticos específicos. Para a variável de saída, "iniciar ultrapassagem", foram definidos os termos linguísticos "sim" e "não", representando as possíveis decisões do sistema. O processo de defuzzificação foi realizado utilizando o método do centro de gravidade (centroid), amplamente reconhecido por sua capacidade de proporcionar uma decisão balanceada ao calcular o ponto central da área sob a curva resultante da inferência. Este método foi selecionado por sua eficácia em fornecer uma saída precisa, considerando a natureza contínua e gradual das variáveis envolvidas.

4.6 Ferramentas Utilizadas

Para a implementação do sistema de inferência nebulosa e análise dos resultados, foram utilizadas diversas bibliotecas amplamente reconhecidas na comunidade de ciência de dados, inteligência artificial e aprendizado de máquina. Dentre elas, destacam-se:

skfuzzy: Utilizada para a modelagem das variáveis linguísticas, criação das funções de pertinência e execução do processo de inferência nebulosa. A **skfuzzy** proporciona um conjunto robusto de ferramentas para o desenvolvimento de sistemas baseados em lógica nebulosa, permitindo a definição e manipulação de variáveis, regras de inferência e operações de controle.

numpy: Usada para a manipulação eficiente de arrays numéricos e cálculos vetoriais, garantindo que o sistema possa processar grandes volumes de dados de maneira ágil e eficiente.

matplotlib: Essencial para a visualização gráfica das funções de pertinência e para a criação de gráficos detalhados, como a matriz de confusão, facilitando a análise visual do comportamento das variáveis e a avaliação dos resultados.

seaborn: Biblioteca de visualização baseada em **matplotlib**, que foi utilizada para criar gráficos de alta qualidade, como mapas de calor da matriz de confusão, proporcionando maior clareza e facilidade de interpretação dos resultados.

sklearn: Ferramenta fundamental para a avaliação do desempenho do sistema, sendo utilizada para o cálculo de métricas como acurácia, precisão, recall e F1-score. Adicionalmente, a biblioteca **sklearn** foi usada para criar a matriz de confusão e realizar a validação dos modelos de inferência nebulosa.

imblearn: Foi empregada para o balanceamento de classes por meio das técnicas de undersampling e oversampling. Essas técnicas foram cruciais para lidar com problemas de desbalanceamento nas classes do dataset, garantindo que o modelo fosse treinado e validado de forma justa e eficaz.

pandas: Utilizada para manipulação e análise de dados, proporcionando uma estrutura eficiente para a criação, armazenamento e carregamento de datasets. Além disso, o **pandas** foi utilizado para organizar os dados e realizar operações de filtragem e agregação, facilitando o processo de simulação e avaliação do modelo.

random: Utilizada para gerar cenários de teste aleatórios, permitindo simulações variadas que abrangem diferentes condições de estrada, velocidade e visibilidade.

Essas bibliotecas foram escolhidas por sua robustez, confiabilidade e ampla adoção na comunidade científica. Elas fornecem um conjunto completo de ferramentas para a implementação, simulação, avaliação e visualização de um sistema de inferência nebulosa eficiente e preciso.

5 Resultados

Os resultados obtidos demonstram que o sistema de inferência nebulosa desenvolvido apresentou um desempenho satisfatório na tomada de decisões de ultrapassagem, com base nas condições de visibilidade, distância e velocidade relativa. Através dos testes simulados, o modelo foi capaz de identificar corretamente as situações em que a ultrapassagem deveria ou não ser recomendada, de acordo com as regras previamente estabelecidas.

A tabela a seguir apresenta as principais métricas de avaliação do modelo, para a base de dados balanceada:

Tabela 1 – Métricas de Avaliação do Sistema de Inferência Nebulosa (Base Balanceada)

Métrica	Valor
Acurácia	0.87
Precisão	0.95
Sensibilidade (Recall)	0.78
F1-Score	0.85




Figura 6 – Matriz de Confusão para Base Balanceada.

5.1 Simulação de Cenários

Para validar o sistema de inferência nebulosa, foram realizados testes em cenários variados, gerados de forma aleatória, com diferentes combinações de distância, velocidade relativa, permissão de ultrapassagem, condições da pista e visibilidade. Esses cenários simulam diferentes condições de tráfego, avaliando a capacidade do sistema em tomar decisões consistentes com as regras estabelecidas.

5.1.1 Testes com Base Desbalanceada

A primeira simulação foi realizada com uma base de dados desbalanceada, composta por 1000 casos. Essa base apresentou uma distribuição desigual entre os casos de "ultrapassar" e "não ultrapassar", refletindo situações de tráfego mais comuns, onde a maioria dos cenários não favorecia a ultrapassagem.

A matriz de confusão para essa simulação foi a seguinte:




Figura 7 – Matriz de Confusão para Base Desbalanceada.

As métricas de avaliação obtidas foram:

Tabela 2 – Métricas de Avaliação do Sistema de Inferência Nebulosa (Base Desbalanceada)

Métrica	Valor
Acurácia	0.93
Precisão	0.42
Sensibilidade (Recall)	0.79
F1-Score	0.55

Os resultados indicam que, embora a acurácia tenha sido alta, a precisão foi baixa (0.42), refletindo dificuldades em classificar corretamente todas as instâncias de "ultrapassar", gerando falsos positivos. A sensibilidade (recall) de 0.79 sugere que o sistema foi eficaz em detectar os casos corretos de ultrapassagem.

5.1.2 Testes com Base Balanceada

Após o balanceamento das classes, uma nova simulação foi realizada com 105 registros. O objetivo foi avaliar o desempenho do sistema em um cenário mais equilibrado entre os

casos de "ultrapassar" e "não ultrapassar". A matriz de confusão obtida foi:




Figura 8 – Matriz de Confusão para Base Balanceada.

As métricas de avaliação para essa simulação foram:

Tabela 3 – Métricas de Avaliação do Sistema de Inferência Nebulosa (Base Balanceada)

Métrica	Valor
Acurácia	0.87
Precisão	0.93
Sensibilidade (Recall)	0.79
F1-Score	0.85

Os resultados com a base balanceada mostram uma melhoria significativa na precisão, que passou para 0.93. Isso demonstra que o sistema foi mais assertivo em identificar corretamente as situações de ultrapassagem, mantendo a sensibilidade constante em 0.79. A F1-Score de 0.85 reflete o bom equilíbrio entre precisão e sensibilidade.

5.1.3 Comparação de Resultados

A tabela a seguir compara as métricas de desempenho entre os testes com bases desbalanceada e balanceada:

6 Discussão dos Resultados

Os resultados das simulações demonstram que o balanceamento das classes foi essencial para melhorar a precisão do sistema. Com a base desbalanceada, o sistema apresentou

Tabela 4 – Comparação de Métricas entre Bases Desbalanceada e Balanceada

Métrica	Base Desbalanceada	Base Balanceada
Acurácia	0.93	0.87
Precisão	0.42	0.93
Sensibilidade (Recall)	0.79	0.79
F1-Score	0.55	0.85

uma acurácia elevada, mas com uma baixa precisão, o que gerou muitos falsos positivos. Após o balanceamento, a precisão subiu consideravelmente, reduzindo o número de falsos positivos e melhorando a capacidade do sistema de identificar corretamente as situações de ultrapassagem.

A consistência do recall em ambos os cenários (0.79) indica que o sistema foi eficaz em detectar corretamente a maioria dos casos em que a ultrapassagem deveria ocorrer. O F1-Score de 0.85 com a base balanceada reflete o bom equilíbrio entre precisão e sensibilidade.

No entanto, é importante destacar que, mesmo com a base desbalanceada, o sistema manteve uma alta acurácia. Isso sugere que o sistema foi capaz de evitar ultrapassagens em cenários não favoráveis, o que é crucial para garantir a segurança em um ambiente de tráfego real.

7 Conclusão

Este trabalho apresentou um sistema de inferência nebulosa aplicado ao controle de ultrapassagem em veículos terrestres autônomos. A lógica fuzzy provou ser uma abordagem eficiente para lidar com a incerteza e a subjetividade das condições de tráfego, resultando em decisões seguras e assertivas.

Os resultados mostram que o balanceamento das classes foi fundamental para aumentar a precisão e a sensibilidade do sistema. Para trabalhos futuros, recomendamos a integração deste sistema com algoritmos de aprendizado de máquina, com o objetivo de otimizar as regras de inferência e melhorar a detecção de cenários complexos.

Além disso, testes em ambientes simulados mais realistas ou em cenários de tráfego real são essenciais para validar a eficácia do sistema em condições de operação mais amplas.

Referências

F. Oquendo, “Fuzzy mediating control systems for automating vehicle driving maneuvers: The overtaking case,” in *TENCON 2023 - 2023 IEEE Region 10 Conference (TENCON)*, 2023, pp. 789–794.

S.-T. Huan, Y.-C. Lin, and C.-L. Lin, "Design and implementation of intelligent overtaking system using model predictive control," in *2020 International Automatic Control Conference (CACCS)*, 2020, pp. 1–6.

J. E. Naranjo, C. Gonzalez, R. Garcia, and T. de Pedro, "Lane-change fuzzy control in autonomous vehicles for the overtaking maneuver," *IEEE Transactions on Intelligent Transportation Systems*, vol. 9, no. 3, pp. 438–450, 2008.

H.-H. Chiang, Y.-L. Chen, B.-F. Wu, and T.-T. Lee, "Embedded driver-assistance system using multiple sensors for safe overtaking maneuver," *IEEE Systems Journal*, vol. 8, no. 3, pp. 681–698, 2014.